Sesión 4
Analizador Sintáctico: Introducción, Gramáticas y Métodos de Análisis Sintáctico Descendente (ASD)

Antonio Moratilla Ocaña

Resumen del tema

- Objetivo:
  - Conocer las responsabilidades de un analizador sintáctico y las construcciones que necesita para poder ser utilizado.

Posición en el diagrama

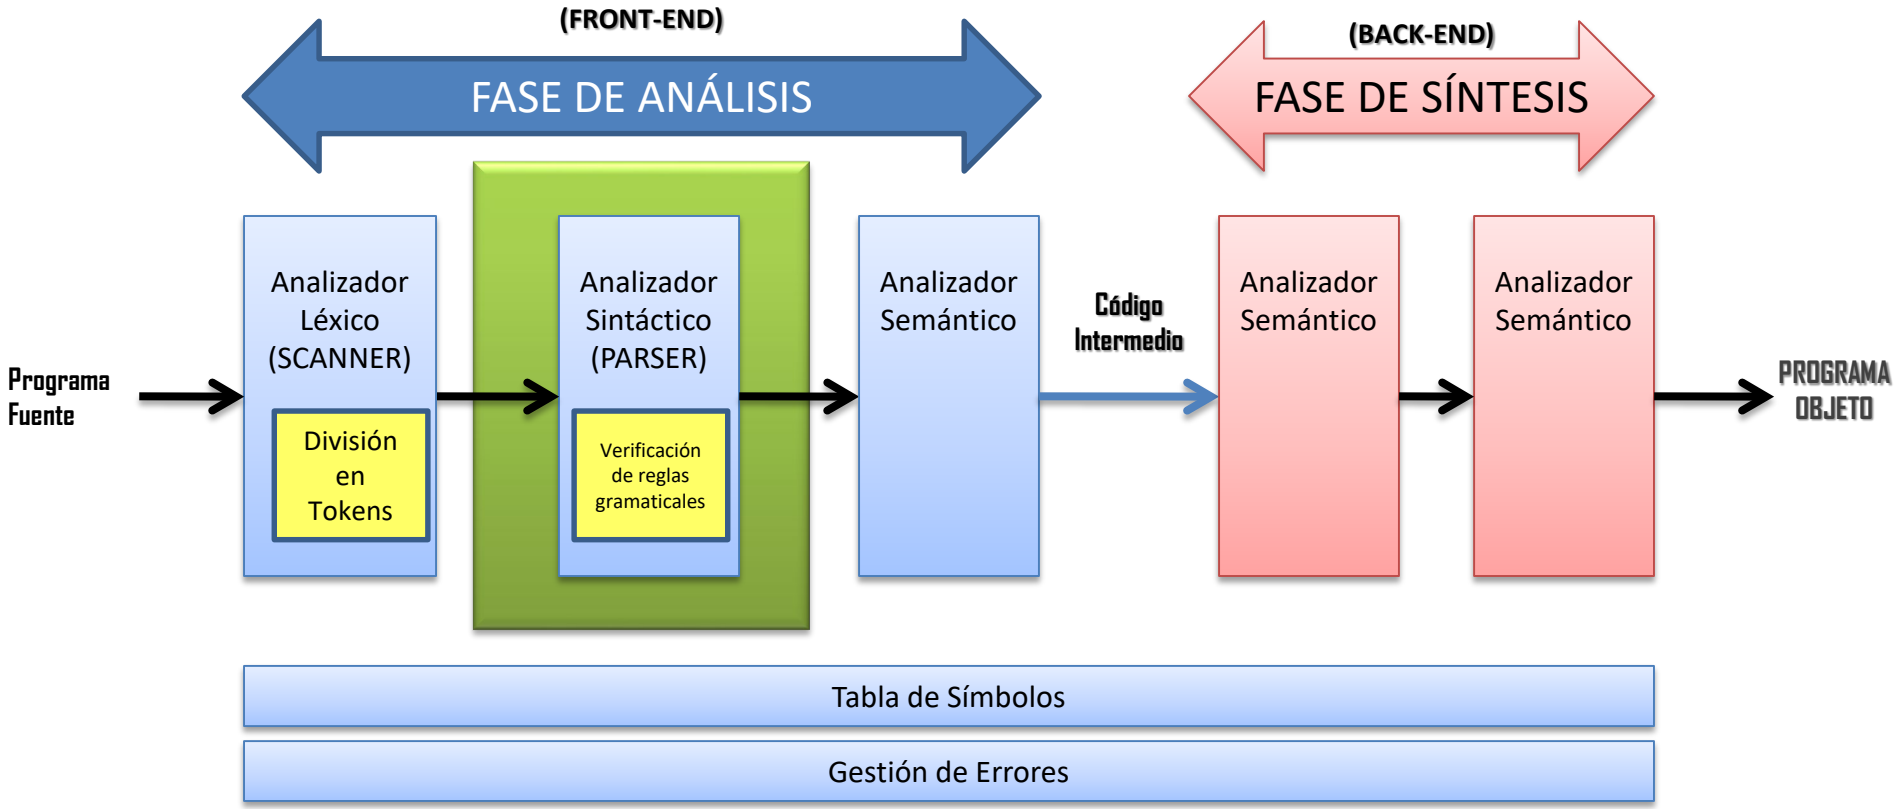

Retomando el hilo...

- Ya sabemos
  - Que los analizadores léxicos leen un fichero de entrada, y lo convierten en TOKENS.
- Lo que queremos saber
  - Y ahora… ¿qué hacemos con los tokens? ¿cómo lo hacemos?

Función del analizador sintáctico

- El **analizador sintáctico** construye una representación intermedia del programa analizado.
  - Construye un árbol de análisis a partir de los componentes léxicos que recibe, aplicando las producciones de la gramática con el objeto de comprobar la corrección sintáctica de las frases.
- Comprobar que el orden en que el analizador léxico le va entregando los *tokens* es válido:
  - Para ello verifica que la cadena pueda ser generada por la **gramática** del lenguaje fuente.
- Informar acerca de los errores de sintaxis, recuperándose de los mismos (si es posible) para continuar procesando la entrada.

Ejemplo de Analizador sintáctico

- Dada la expresión: “2 –3 + 5”
- El analizador sintáctico utiliza las reglas de producción de la gramática para construir el árbol sintáctico.

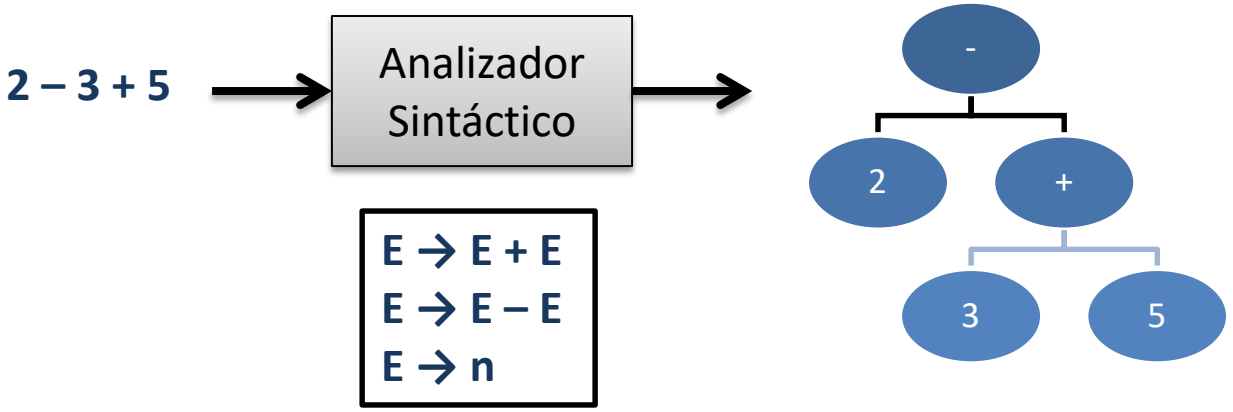

Gramática Independiente del Contexto

- La sintaxis de un lenguaje se especifica mediante las denominadas **Gramáticas Independientes del Contexto.**
  - Una Gramática Independientes del Contexto (GIC) es una gramática formal en la que cada regla de producción es de la forma: **Exp → x**

    Donde *Exp* es un símbolo no terminal y x es una cadena de terminales y/o no terminales. El término independiente del contexto se refiere al hecho de que el no terminal *Exp* puede siempre ser sustituido por x sin tener en cuenta el contexto en el que ocurra.

    Un lenguaje formal es independiente de contexto si hay una gramática libre de contexto que lo genera.

UTILIZACIÓN

- Describen de forma natural la estructura jerárquica de las construcciones de los lenguajes de programación.
- Facilitan la construcción de analizadores sintácticos eficientes.
- Impone una estructura al lenguaje que posteriormente resulta útil para su traducción a código objeto y para la detección de errores.
- Facilitan la extensión (ampliación con nuevas construcciones) del lenguaje.

Axioma: Para cualquier Gramática Independiente del Contexto se puede construir un analizador sintáctico.

Gramática Independiente del Contexto

Componentes de una gramática: $G = (V_t, V_n, S, P)$

- Símbolos terminales(componentes léxicos [tokens]), $\mathbf{V_t}$
- Símbolos no-terminales, $\mathbf{V_n}$
- Símbolo inicial o axioma, **S**
- Producciones, formadas por no-terminales y terminales, **P**

Una gramática se describe

– Mostrando una lista de sus producciones.

- Una producción consta de un símbolo no-terminal (parte izquierda), una flecha, y una secuencia de símbolos terminales y no-terminales (parte derecha).

  E → E + E

  E → E – E

  E → n

– Usando la notación Backus-Naur Form (BNF) o Extended BNF (EBNF)

BNF -Backus-Naur Form

- Es una notación alternativa para la especificación de producciones (BNF –Backus-Naur Form).

  Representación.

  ::= significa “se define como”

  | significa "or lógico"

  < > encierran los no-terminales

  Los terminales se escriben tal y como son.

Ejemplos:

1. <identificador>::=<letra>|<identificador>[<letra>|<dígito>]
2. <nombre_completo> ::= [<trato>] <nombre> <apellidos> | <apellidos> , <nombre>
3. *<validchar>* ::= <letter> | <digit> | _
   <letter> ::= a|b|c|d|e|f|g|h|i|j|k|l|m|n|o|p|q|r|s|t|u|v|w|x|y|z
   |A|B|C|D|E|F|G|H|I|J|K|L|M|N|O|P|Q|R|S|T|U|V|W|X|Y|Z
   <digit> ::= 1|2|3|4|5|6|7|8|9|0

Amplía sobre BNF en http://www.garshol.priv.no/download/text/bnf.html

Lenguaje definido por una gramática

- Un lenguaje definido por una gramática es el conjunto de cadenas de componentes léxicos derivadas del símbolo inicial de la gramática.

$$L(G) = \{s \mid exp \rightarrow * s\}$$

Ejemplos:

1. $E \rightarrow (E) \mid a$ $\quad\quad$ $L(G) = \{(a), ((a)), (((a))), \ldots\}$

2. $E \rightarrow E+ a \mid a$ $\quad\quad$ $L(G) = \{a, a+a, a+a+a, \ldots\}$

Árbol gramatical

Un árbol gramatical correspondiente a una derivación es un árbol etiquetado en el cual los nodos interiores están etiquetados por no terminales, los nodos hoja están etiquetados por terminales, y los hijos de cada nodo interno representan el reemplazo del no terminal asociado en un paso de la derivación

Ejemplo:

```
EXP → EXP OP EXP
EXP → numero
OP → +
OP → -
```

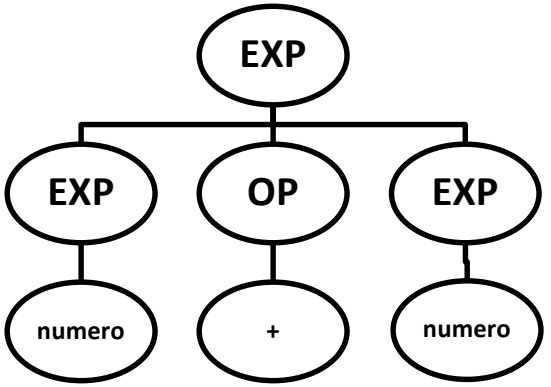

Derivaciones

Se denomina derivación a la sucesión de una o más producciones:

$$A_1 \Rightarrow A_2 \Rightarrow A_3 \Rightarrow \ldots \Rightarrow A_n \text{ o también } A_1 \Rightarrow A_n$$

- Una cadena de componentes léxicos es considerada válida si existe una derivación en la gramática del lenguaje fuente que parta del símbolo inicial y tras aplicar las producciones a los no terminales, genere la frase a reconocer.
- Las derivaciones pueden ser por la izquierda o por la derecha (canónicas).

  –Derivación por la izquierda: sólo el no-terminal de más a la izquierda de cualquier forma de frase se sustituye en cada paso:

  E →E + E | E * E | (E) | -E | id

  E => -E => -(E) => -(E+E) => -(id+E) => -(id+id)

Reglas de producción - Recursividad

Permite expresar iteración utilizando un número pequeño de reglas de producción.

La estructura de las producciones recursivas es:

- Una o más reglas no recursivas que se definen como caso base.
- Una o más reglas recursivas que permiten el crecimiento a partir del caso base.

Ejemplo:

Estructura de un tren formado por una locomotora y un número de vagones cualquiera detrás.

Solución 1 (no recursiva):

tren → locomotora
tren → locomotora vagón
tren → locomotora vagón vagón ...

Solución 2 (recursiva):

Regla base: tren → locomotora
Regla recursiva : tren → tren vagón

La regla recursiva permite el crecimiento ilimitado

Reglas de producción - Recursividad

Una gramática se dice que es recursiva si en una derivación de un símbolo no-terminal aparece dicho símbolo en la parte derecha: A *=> aAb

Tipos de recursividad:

- Por la izquierda: Problemática para el análisis descendente, funciona bien en los analizadores ascendentes. A *=> Ab
- Por la derecha: Utilizada para el análisis descendente. A *=> aA
- Por ambos lados: No se utiliza porque produce gramáticas ambiguas.

- Transformar la recursividad: A=>Aa|b →

  A=>bC

  C=aC|Ɛ

Reglas de producción - Ambigüedad

Una gramática es ambigüa si el lenguaje que define contiene alguna cadena que pueda ser generada por más de un árbol sintáctico distinto aplicando las producciones de la gramática.

- Para la mayoría analizadores sintácticos es preferible que la gramática no sea ambigua
  - Es complicado conseguir en todos los casos la misma representación intermedia.
  - El analizador resultante puede no ser tan eficiente
- Es posible, mediante ciertas restricciones, garantizar la no ambigüedad de una gramática.

- Algunos generadores automáticos son capaces de manejar gramáticas ambiguas, no obstante se deben proporcionar reglas para evitar la ambigüedad y generar un único árbol sintáctico.

Reglas de producción - Ambigüedad

- Evitar producciones recursivas en las que las variables no recursivas de la producción puedan derivar a la cadena vacía

  S → **HR**S S → s H → h | ε R → r | ε

- No permitir ciclos : S →A S →a **A →S**
- Suprimir reglas que ofrezcan caminos alternativos

  S → A S → B **A → B**

La ambigüedad implica que a una misma sentencia se le pueden asignar significados (semánticas) diferentes.

- El algoritmo para poder crear un árbol sintáctico para una gramática ambigua necesita de prueba y retroceso
- Si un lenguaje es ambiguo existirán varios significados posibles para el mismo programa, y por tanto el compilador podría generar varios códigos máquina diferentes para un mismo código fuente.
- Un análisis sintáctico determinista (sin posibilidad de elegir entre varias opciones) es más eficiente

Las gramáticas de los lenguajes de programación no deben ser ambiguas.

Reglas de producción - Ambigüedad

EJEMPLO DE AMBIGÜEDAD

E → E + E
E → E * E
E → (E)
E → n

Expresión
2+3*5

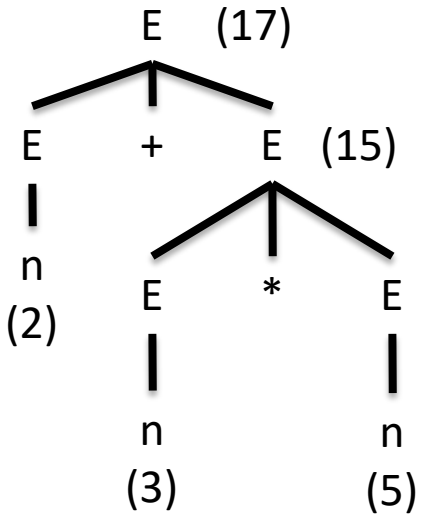

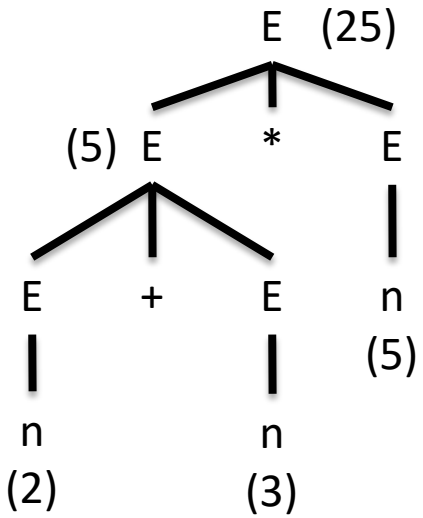

Producciones
E → E + E
→ n + E
→ n + E * E
→ n + n * E
→ n + n * n

Producciones
E → E * E
→ E + E * E
→ n + E * E
→ n + n * E
→ n + n * n

Reglas de producción - Ambigüedad

SOLUCIÓN A LA AMBIGÜEDAD

E → E + T | T
T → T * F | F
F → (E) | n

Expresión
2+3*5

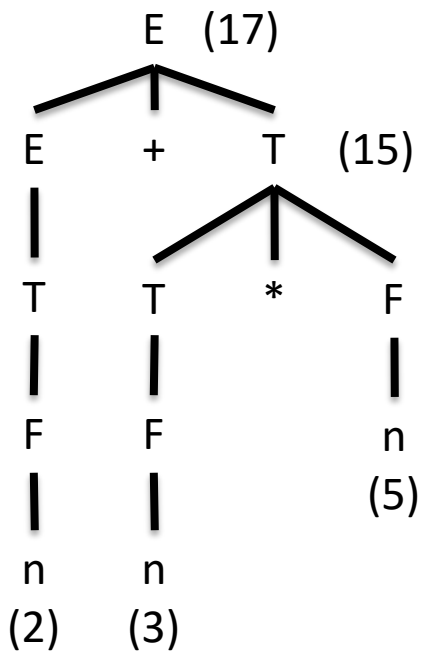

Producciones

E → E + E
→ n + E
→ n + E * E
→ n + n * E
→ n + n * n

Tipos de analizador sintáctico

- Para comprobar si una cadena pertenece al lenguaje generado por una gramática, los analizadores sintácticos construyen una representación en forma de árbol de 2 posibles métodos:
  - **Analizadores sintácticos descendentes** (Top-down) (ASD)
    - Construyen el árbol sintáctico de la raíz (arriba) a las hojas (abajo).
    - Parten del símbolo inicial de la gramática (*axioma*) y van expandiendo producciones hasta llegar a la cadena de entrada.
  - **Analizadores sintácticos ascendentes** (Bottom-up) (ASA)
    - Construyen el árbol sintáctico comenzando por las hojas.
    - Parten de los terminales de la entrada y mediante reducciones llegan hasta el símbolo inicial.
  - En ambos casos se examina la entrada de izquierda a derecha, analizando los testigos o tokens de entrada de uno en uno.

- Notas:
  1. Los métodos descendentes se pueden implementar más fácilmente sin necesidad de utilizar generadores automáticos.
  2. Los métodos ascendentes pueden manejar una mayor gama de gramáticas por lo que los generadores automáticos suelen utilizarlos.
  3. Para cualquier gramática independiente de contexto hay un analizador sintáctico "general" que toma como máximo un tiempo de $O(n^3)$ para realizar el análisis de una cadena de n componentes léxicos. Se puede conseguir un análisis lineal O(n)para la mayoría de lenguajes de programación.

Retomando el hilo...

- Ya sabemos
  - Que las gramáticas nos permiten definir un lenguaje
- Lo que queremos saber
  - ¿Cómo sabemos si una entrada corresponde con un lenguaje definido por una gramática?

Análisis Sintáctico Descendente - ASD

Métodos que parten del axioma y, mediante derivaciones por la izquierda, tratan de encontrar la entrada.

- Existen dos formas de implementarlos:
  - **Análisis descendente recursivo**
    - Es la manera más sencilla, implementándose con una función recursiva aprovechando la recursividad de la gramática.
  - **Análisis descendente predictivo**
    - Para aumentar la eficiencia, evitando los retrocesos, se predicen cada momento cuál de las reglas sintácticas hay que aplicar para continuar el análisis
    - En la práctica apenas se emplea el recursivo (o con retroceso) debido a diversos inconvenientes.

ASD - Recursivo

A. Mediante un método de ***backtracking*** se van probando todas las opciones de expansión para cada no-terminal de la gramática hasta encontrar la correcta.

B. Cada retroceso en el árbol sintáctico tiene asociado un retroceso en la entrada: Se deben eliminar todos los terminales y no terminales correspondientes a la producción que se “elimina” del árbol.

C. Si el terminal obtenido como consecuencia de probar con una opción de las varias de una producción no coincide con el componente léxico leído en la entrada, hay que retroceder.

Algoritmo del ASD - Recursivo

1) Se colocan las reglas en orden, de forma que si la parte derecha de una producción es prefijo de otra, esta última se sitúa detrás.
2) Se crea el nodo inicial con el axioma y se considera nodo activo.
3) Para cada nodo activo A:
   a) Si A es un no-terminal, se aplica la primera producción asociada a A.
      1) El nodo activo pasa a ser el hijo izquierdo.
      2) Cuando se terminan de tratar todos los descendientes, el siguiente nodo activo es el siguiente hijo por la izquierda.
   b) Si A es un terminal :
      1) Si coincide el símbolo de la entrada, se avanza el puntero de entrada y el nodo activo pasa a ser el siguiente "hermano" de A.
      2) Si no, se retrocede en el árbol hasta el anterior no-terminal (y en la entrada si se ha reconocido algún componente léxico mediante la producción que se elimina) y se prueba la siguiente producción.
         – Si no hay más producciones para probar, se retrocede hasta el anterior no-terminal y se prueba con la siguiente opción de éste.
4) Si se acaban todas las opciones del nodo inicial, error sintáctico. Si por el contrario se encuentra un árbol para la cadena de entrada, éxito.

Algoritmo del ASD recursivo

Ejemplo :

Comprobar si la cadena **ccd** pertenece al lenguaje de la gramática:

G(S → c X d ; X → c k | c)

Algoritmo del ASD recursivo

Elementos auxiliares:

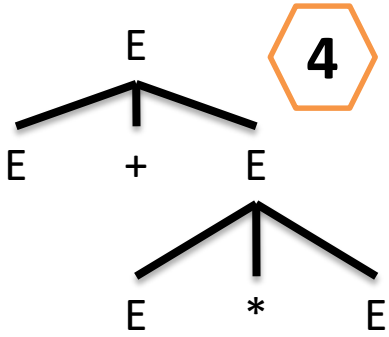

2

PILA

Entrada 1

3

ccd para G(S → c X d ; X → c k | c)

Entrada	Pila	Regla a aplicar	Se obtiene en la pila	Se empareja con la entrada	Queda en la pila	Queda en la entrada

Algoritmo del ASD recursivo

Entrada

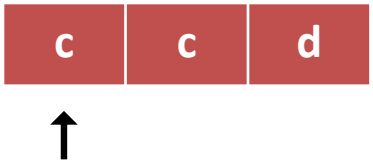

PILA
S

ccd para G(S → c X d ; X → c k | c)

Entrada	Pila	Regla a aplicar	Se obtiene en la pila	Se empareja con la entrada	Queda en la pila	Queda en la entrada
c c d	S					

Algoritmo del ASD recursivo

Regla

- S → c X d

Entrada

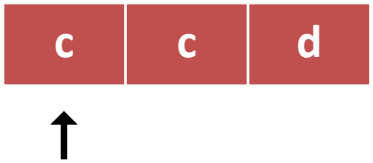

PILA
d
X
c

ccd para G(S → c X d ; X → c k | c)

Entrada	Pila	Regla a aplicar	Se obtiene en la pila	Se empareja con la entrada	Queda en la pila	Queda en la entrada
c c d	S	S → c X d	c X d			

Algoritmo del ASD recursivo

Regla

- S → c X d

Entrada

c	c	d

↑

PILA
d
X
c

ccd para G(S → c X d ; X → c k | c)

Entrada	Pila	Regla a aplicar	Se obtiene en la pila	Se empareja con la entrada	Queda en la pila	Queda en la entrada
c c d	S	S → c X d	c X d	c	X d	c d

Algoritmo del ASD recursivo

Regla

- S → c X d

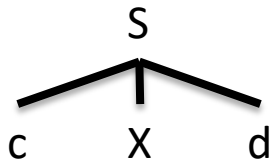

Entrada

c	c	d

↑

PILA
d
X

ccd para G(S → c X d ; X → c k | c)

Entrada	Pila	Regla a aplicar	Se obtiene en la pila	Se empareja con la entrada	Queda en la pila	Queda en la entrada
c c d	S	S → c X d	c X d	c	X d	c d

Algoritmo del ASD recursivo

Regla

- S → c X d

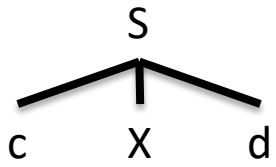

Entrada

c	c	d

↑

PILA
d
X

ccd para G(S → c X d ; X → c k | c)

Entrada	Pila	Regla a aplicar	Se obtiene en la pila	Se empareja con la entrada	Queda en la pila	Queda en la entrada
c c d	S	S → c X d	c X d	c	X d	c d
c d	X d					

Algoritmo del ASD recursivo

Regla
X → c k

Entrada

c	c	d
↑		

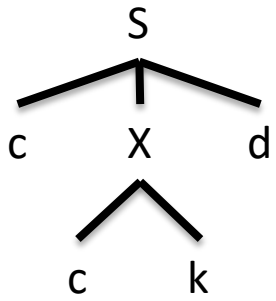

PILA
d
k
c

ccd para G(S → c X d ; X → c k | c)

Entrada	Pila	Regla a aplicar	Se obtiene en la pila	Se empareja con la entrada	Queda en la pila	Queda en la entrada
c c d	S	S → c X d	c X d	c	X d	c d
c d	X d	X → c k	c k d			

Algoritmo del ASD recursivo

Regla
X → c k

Entrada

c	c	d
↑		

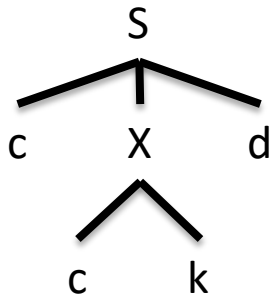

PILA
d
k
c

ccd para G(S → c X d ; X → c k | c)

Entrada	Pila	Regla a aplicar	Se obtiene en la pila	Se empareja con la entrada	Queda en la pila	Queda en la entrada
c c d	S	S → c X d	c X d	c	X d	c d
c d	X d	X → c k	c k d	c	k d	d

Algoritmo del ASD recursivo

Regla
X → c k

Entrada

c	c	d
		↑

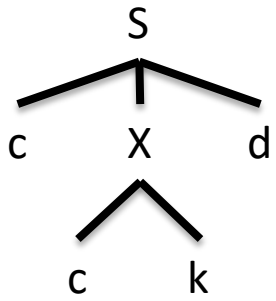

PILA
d
k

ccd para G(S → c X d ; X → c k | c)

Entrada	Pila	Regla a aplicar	Se obtiene en la pila	Se empareja con la entrada	Queda en la pila	Queda en la entrada
c c d	S	S → c X d	c X d	c	X d	c d
c d	X d	X → c k	c k d	c	k d	d
d	d k	d y k no se emparejan, hay que deshacer el último paso (2) y probar la siguiente regla				

Algoritmo del ASD recursivo

Regla
X → c k

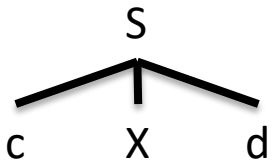

Entrada

c	c	d
↑		

PILA
d
X

ccd para G(S → c X d ; X → c k | c)

Entrada	Pila	Regla a aplicar	Se obtiene en la pila	Se empareja con la entrada	Queda en la pila	Queda en la entrada
c c d	S	S → c X d	c X d	c	X d	c d
c d	X d	X → c k	c k d	c	k d	d
d	d k	d y k no se emparejan, hay que deshacer el último paso (2) y probar la siguiente regla				
c d	X d	X → c				

Algoritmo del ASD recursivo

Regla
X → c k

Entrada

c	c	d

↑

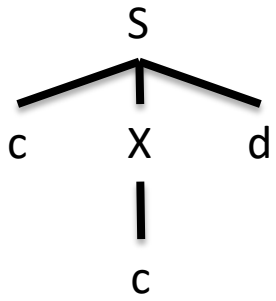

PILA
d
c

ccd para G(S → c X d ; X → c k | c)

Entrada	Pila	Regla a aplicar	Se obtiene en la pila	Se empareja con la entrada	Queda en la pila	Queda en la entrada
c c d	S	S → c X d	c X d	c	X d	c d
c d	X d	X → c k	c k d	c	k d	d
d	d k	d y k no se emparejan, hay que deshacer el último paso (2) y probar la siguiente regla				
c d	X d	X → c	c d	c	d	d

Algoritmo del ASD recursivo

Regla
X → c k

Entrada

c	c	d
	↑	

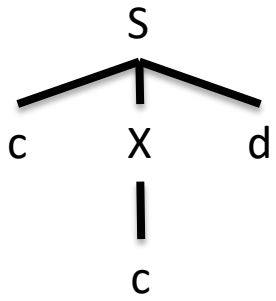

PILA
d

ccd para G(S → c X d ; X → c k | c)

Entrada	Pila	Regla a aplicar	Se obtiene en la pila	Se empareja con la entrada	Queda en la pila	Queda en la entrada
c c d	S	S → c X d	c X d	c	X d	c d
c d	X d	X → c k	c k d	c	k d	d
d	d k	d y k no se emparejan, hay que deshacer el último paso (2) y probar la siguiente regla				
c d	X d	X → c	c d	c	d	d
d	d			d		

ASD Recursivo - Problemas

- No puede tratar gramáticas con recursividad a izquierdas.

A → Abc

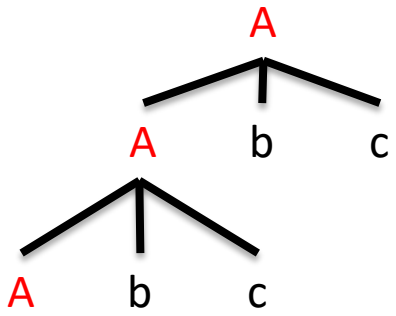

- Acaba la ejecución cuando se encuentra el primer error
  - Difícil proporcionar mensajes más elaborados que “correcto” o “incorrecto”, como por ejemplo especificar dónde se ha encontrado el error.
- Aunque la programación es simple, utiliza muchos recursos
  - Como consecuencia del retroceso necesita almacenar los componentes léxicos ya reconocidos por si es necesario volverlos a tratar.
- Cuando un analizador sintáctico se utiliza para comprobar la semántica y generar código, cada vez que se expande una regla, se ejecuta una acción semántica. Al retroceder esa regla o producción se deben deshacer las acciones semánticas, lo que no es fácil ni siempre posible.

ASD Recursivo

Eliminación de la recursividad por la izquierda

Recursión inmediata

Si la gramática recursiva tiene la forma siguiente:

$$A \rightarrow A\alpha_1 | A\alpha_2 | \ldots | A\alpha_n | \beta_1 | \beta_2 | \ldots | \beta_m$$

A es el no-terminal recursivo.

$\boldsymbol{\alpha_i}$, partes derechas de las reglas recursivas del no terminal A.

$\boldsymbol{\beta_i}$, partes derechas de las reglas no recursivas del no terminal A.

La gramática no recursiva equivalente será:

$$A \rightarrow \beta_1 A' | \beta_2 A' | \ldots | \beta_m A'$$

$$A' \rightarrow \alpha_1 A' | \alpha_2 A' | \ldots | \alpha_m A' | \varepsilon$$

ASD Recursivo

Eliminación de la recursividad por la izquierda

Recursión indirecta

Para eliminarla recursividad indirecta se debe encontrar el elemento conflictivo y sustituirlo por su definición.

Ejemplo

S → A a | b

A → A c | **S** d | Ɛ (A → S d es recursiva por S → Aa)

Sustituímos

S → A a | b

A → A c | A a d | b d | Ɛ

Y eliminamos la recursión inmediata de A como antes:

S → A a | b

A → b d A' | A'

A' → c A' | a d A' | Ɛ

ASD Predictivo

- Intentan predecir la siguiente construcción a aplicar leyendo uno o más componentes léxicos por adelantado
  - "Saben" con exactitud qué regla deben expandir para llegar a la entrada
- Este tipo de analizadores se denomina LL(k)
  - Leen la entrada de izquierda a derecha (Left to rigth)
  - Aplican derivaciones por la izquierda para cada entrada (Left)
  - Utilizan k componentes léxicos de la entrada para predecir la dirección del análisis.
- Están formados por:
  - Un buffer para la entrada.
  - Una pila de análisis.
  - Una tabla de análisis sintáctico.
  - Una rutina de control.

ASD Predictivo

- En función de la entrada, de la tabla de análisis y de la pila decide la acción a realizar.

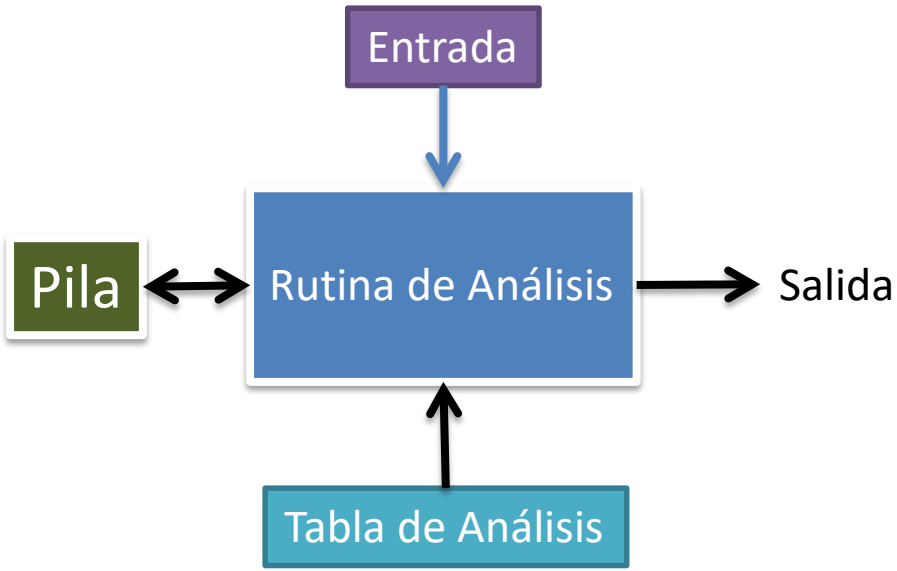

Posibles Acciones:

1. **Aceptar la cadena.**
2. **Aplicar Producción.**
3. **Pasar al siguiente símbolo de entrada.**
4. **Notificar Error.**

ASD Predictivo Tabla de análisis sintáctico

- Se trata de una matriz **M [Vn, Vt]** donde se representan las producciones a expandir en función del estado actual del análisis y del símbolo de la entrada.
- Las entradas en blanco indican errores

	a	b	c	d	e	$
S	S → BA	error	error	S → BA	error	error
A	error	A → bSC	error	error	A → Ɛ	A → Ɛ
B	B → DC	error	error	B → DC	error	error
C	error	C→ Ɛ	C→ cDC	error	C→ Ɛ	C→ Ɛ
D	D→ a	error	error	D→ dSe	error	error

ASD Predictivo - Ejemplo

GRAMATICA		Cadena entrada	Símbolo en la entrada	Regla a aplicar *	Pila	Derivaciones aplicadas
A→B **A→aBc** **A→xC** **B→bA** **C→c**	1	babxcc	b	A→B	B	B
	2	babxcc	b	B→bA	bA	bA
	3	abxcc	a	A→aBc	aBc	baBc
	4	bxcc	b	B→bA	bAc	babAc
	5	xcc	x	A→xC	xCc	babxCc
	6	cc	c	C→c	cc	babxcc
	7	c	c		c	babxcc
	8					babxcc

* La regla a aplicar vendría dada por la tabla de análisis sintáctico.

Ejercicios

- Dada la gramática G(A → a B b ; B → c d | c)
- Realice en proceso de análisis sintáctico descendente recursivo para reconocer las expresiones
  - acdb
  - abcd
  - acb

Fuentes

- Para la elaboración de estas transparencias se han utilizado:
  - Transparencias de cursos previos (elaboradas por los profesores Dr. D. Salvador Sánchez, Dr. D. José Luis Cuadrado).
  - Libros de referencia (en especial capítulos 2 y 4 de Aho).